

Offline RL 中根據目前表現選擇 Subdataset 的研究提案

零、背景與痛點

Offline RL 只能從固定 dataset 學習，不能靠新的 environment interaction 修正錯誤，因此 data quality 與 data selection 會強烈影響 policy learning。若模型仍很弱，直接要求它從非常強的 trajectory 學習，可能因 state/action distribution 差太多而學不到有效更新；反過來，若模型已經很強，繼續大量學習低 reward trajectory，也可能只是在模仿次佳甚至錯誤行為。這表示 offline RL 可能不該在整個訓練過程中固定使用同一批資料，而需要根據 learner 當前能力調整 training subset。

一、研究想法

本研究探討一種 **performance-conditioned offline RL curriculum**：先收集大量 trajectories 組成固定 dataset D ，每條 trajectory τ 有 cumulative reward $R(\tau)$ ；訓練 offline RL agent 時，根據目前 policy 的 average performance p ，動態選擇 subdataset D_p 來更新模型。核心問題是：當 agent 目前達到表現 p 時，最適合拿哪些 reward 等級的 trajectories 來學？候選策略包含選擇 reward 接近 p 的 trajectories、選擇略高於目前能力的範圍如 $[p, 1.5p]$ ，或用平滑權重

$$w(\tau; p) \propto \exp\left(-\frac{|R(\tau) - g(p)|}{T}\right)$$

取樣，其中 $g(p)$ 可以是 p 、 $p + \Delta$ 、 $1.2p$ 或依 percentile 設計的函數。實驗將比較 full dataset、top-return dataset、random subset、near- p subset、above- p subset，分析「根據目前能力調整資料難度」是否能提升 learning stability 與 final performance。

二、Dataset 需求與預計任務

此方法需要的 dataset 有三個條件：第一，trajectory return 分布要夠寬，包含低、中、高品質軌跡；第二，reward 要夠 dense，避免 agent 到某個 p 時找不到足夠接近的資料；第三，資料要能大量取得，最好可由不同 training checkpoints、不同強度 policy 或 simulator 自動產生。

- **2584 / HW2 Q3**：先在既有作業環境驗證概念。因現成模型太強，難以收集 low-reward trajectories，因此會從頭訓練一個 2584 agent，保存不同 training stage 的 checkpoints，從弱到強收集 mixed-quality trajectories。2584 的每步合併 tile、分數增加都能形成相對 dense 的 reward，因此可取得較連續的 trajectory return。
- **D4RL / Minari continuous control**：例如 Hopper、Walker2d、HalfCheetah 的 random、medium、medium-replay、medium-expert datasets。這些資料是 offline RL 常用 benchmark，且由不同品質 policy 產生，適合把 trajectories 依 return 排序並測試不同 D_p 規則。MuJoCo 類任務通常每一步都有 forward reward、control cost 或 survival reward，比 sparse success/failure 更 dense。
- **Navigation / Maze**：例如 PointMaze、AntMaze、MiniGrid 或自製 2D navigation。可將 reward 設為 -distance to goal、朝目標前進量或 action cost，使每一步都有回饋。這類任務的 trajectory quality 很直觀：亂走、接近目標、繞遠路成功、快速成功，適合視覺化不同 return band 對學習的影響。

三、相關工作

已有研究和本想法接近，但切入點不同。**Curriculum Offline Reinforcement Learning** (AAMAS 2023) 指出 offline RL 在不同 training stage 需要不同 samples，並根據 current policy 與 data-generating policy 的相似度選資料；本研究則以目前 average performance p 和 trajectory return band 定義 curriculum。**Curriculum Offline Imitation Learning** (NeurIPS 2021) 讓 policy 逐步模仿比自己更好的 neighboring policies，概念上接近「學稍微高於目前能力的資料」，但主要屬於 imitation learning。**Harnessing Mixed Offline RL Datasets via Trajectory Weighting** (ICLR 2023) 與 **Beyond Uniform Sampling** (NeurIPS 2023) 研究 mixed-quality datasets 中如何加權或偏好高品質 trajectories；本研究不同之處在於不固定追求最高分資料，而是比較 near- p 、above- p 、top-return 等策略，檢驗以 learner 當前能力為條件的 data selection 是否更有效。

預期貢獻：系統性分析 offline RL 中「目前能力 p 」與「training trajectories 的 reward range」之關係，找出在 dense reward、mixed-quality trajectories 下，何種 performance-conditioned subdataset selection 最能改善 learning efficiency 與 stability。